

Рубежный контроль 1. Вариант 10. Задача 2. Датасет 2 (wine)

```
In [ ]: import numpy as np
import pandas as pd
import matplotlib.pyplot as plt
from sklearn.datasets import load_wine
```

```
In [ ]: wine = load_wine(as_frame=True)
df = wine.frame.copy()
df.head()
```

```
Out[ ]:   alcohol  malic_acid  ash  alcalinity_of_ash  magnesium  total_phenols  flavanoids  nc
0    14.23         1.71  2.43             15.6         127.0           2.80         3.06
1    13.20         1.78  2.14             11.2         100.0           2.65         2.76
2    13.16         2.36  2.67             18.6         101.0           2.80         3.24
3    14.37         1.95  2.50             16.8         113.0           3.85         3.49
4    13.24         2.59  2.87             21.0         118.0           2.80         2.69
```

```
In [ ]: df.info()
```

```
<class 'pandas.DataFrame'>
RangeIndex: 178 entries, 0 to 177
Data columns (total 14 columns):
#   Column                                Non-Null Count  Dtype
---  -
0   alcohol                               178 non-null    float64
1   malic_acid                            178 non-null    float64
2   ash                                   178 non-null    float64
3   alcalinity_of_ash                     178 non-null    float64
4   magnesium                             178 non-null    float64
5   total_phenols                         178 non-null    float64
6   flavanoids                            178 non-null    float64
7   nonflavanoid_phenols                  178 non-null    float64
8   proanthocyanins                       178 non-null    float64
9   color_intensity                       178 non-null    float64
10  hue                                   178 non-null    float64
11  od280/od315_of_diluted_wines          178 non-null    float64
12  proline                               178 non-null    float64
13  target                                178 non-null    int64
dtypes: float64(13), int64(1)
memory usage: 19.6 KB
```

```
In [ ]: df.describe()
```

	alcohol	malic_acid	ash	alcalinity_of_ash	magnesium	total_phenols
count	178.000000	178.000000	178.000000	178.000000	178.000000	178.000000
mean	13.000618	2.336348	2.366517	19.494944	99.741573	2.295112
std	0.811827	1.117146	0.274344	3.339564	14.282484	0.625851
min	11.030000	0.740000	1.360000	10.600000	70.000000	0.980000
25%	12.362500	1.602500	2.210000	17.200000	88.000000	1.742500
50%	13.050000	1.865000	2.360000	19.500000	98.000000	2.355000
75%	13.677500	3.082500	2.557500	21.500000	107.000000	2.800000
max	14.830000	5.800000	3.230000	30.000000	162.000000	3.880000

Датасет содержит только числовые признаки. Создадим категориальный признак `alcohol_level` на основе содержания алкоголя, разбив значения на три категории по квантилям.

```
In [ ]: q1, q2 = df['alcohol'].quantile([1/3, 2/3])

def categorize_alcohol(val):
    if val < q1:
        return 'low'
    elif val < q2:
        return 'medium'
    else:
        return 'high'

df['alcohol_level'] = df['alcohol'].apply(categorize_alcohol)
df['alcohol_level'].value_counts()
```

```
Out [ ]: alcohol_level
high      61
low       59
medium    58
Name: count, dtype: int64
```

Искусственно вводим пропуски в количественный признак `magnesium` (20% значений) и в категориальный `alcohol_level` (15% значений).

```
In [ ]: np.random.seed(42)

n = len(df)
idx_num = np.random.choice(n, size=int(0.2 * n), replace=False)
idx_cat = np.random.choice(n, size=int(0.15 * n), replace=False)

df.loc[idx_num, 'magnesium'] = np.nan
df.loc[idx_cat, 'alcohol_level'] = np.nan

print("Пропуски после введения:")
print(df[['magnesium', 'alcohol_level']].isnull().sum())
```

```
Пропуски после введения:
magnesium      35
alcohol_level   26
dtype: int64
```

Обработка пропусков

Количественный признак `magnesium` — заполняем медианой. Медиана предпочтительнее среднего, так как устойчива к выбросам. Содержание магния в вине может иметь выбросы (отдельные сорта резко отличаются от остальных), поэтому медиана даёт более робастную оценку центра распределения.

Категориальный признак `alcohol_level` — заполняем модой, то есть наиболее часто встречающейся категорией. Это стандартный подход для категориальных данных.

```
In [ ]: median_magnesium = df['magnesium'].median()
mode_alcohol_level = df['alcohol_level'].mode()[0]

df['magnesium'] = df['magnesium'].fillna(median_magnesium)
df['alcohol_level'] = df['alcohol_level'].fillna(mode_alcohol_level)


print(f"Медиана magnesium: {median_magnesium}")
print(f"Мода alcohol_level: {mode_alcohol_level}")
print("\nПропуски после обработки:")
print(df[['magnesium', 'alcohol_level']].isnull().sum())
```

```
Медиана magnesium: 98.0
Мода alcohol_level: high
```

```
Пропуски после обработки:
magnesium      0
alcohol_level   0
dtype: int64
```

Boxplot для признака `flavanoids`

```
In [ ]: fig, ax = plt.subplots(figsize=(5, 6))
ax.boxplot(df['flavanoids'], patch_artist=True,
           boxprops=dict(facecolor='steelblue', alpha=0.7))
ax.set_title('Boxplot: flavanoids')
ax.set_ylabel('Flavanoids')
ax.set_xticks([])
plt.tight_layout()
plt.show()
```



Выбор признаков для построения моделей

Целевая переменная — `target` (класс вина, 3 класса). Для построения модели классификации используем числовые признаки из исходного датасета.

Исключаем из рассмотрения созданный категориальный признак `alcohol_level`, поскольку он полностью произведен от `alcohol` — использование обоих вместе привело бы к дублированию информации. Признак `alcohol` при этом сохраняем.

Исходные 13 числовых признаков (`alcohol`, `malic_acid`, `ash`, `alcalinity_of_ash`, `magnesium`, `total_phenols`, `flavanoids`, `nonflavanoid_phenols`, `proanthocyanins`, `color_intensity`, `hue`, `od280/od315_of_diluted_wines`, `proline`) используются все, так как они характеризуют химический состав и физические свойства вина — информативны для разделения сортов. Датасет небольшой (178 строк, 13 признаков), мультиколлинеарность можно будет при необходимости устранить на этапе отбора признаков.

```
In [ ]: feature_cols = wine.feature_names
X = df[feature_cols]
y = df['target']

print("Признаки для модели:", feature_cols)
print("Размерность X:", X.shape)
print("Распределение классов:")
print(y.value_counts().sort_index())
```

Признаки для модели: ['alcohol', 'malic_acid', 'ash', 'alcalinity_of_ash', 'magnesium', 'total_phenols', 'flavanoids', 'nonflavanoid_phenols', 'proanthocyanins', 'color_intensity', 'hue', 'od280/od315_of_diluted_wines', 'proline']

Размерность X: (178, 13)

Распределение классов:

target

0 59

1 71

2 48

Name: count, dtype: int64